Projeto 1 Introdução à Inteligência Artificial
Sistema de Recomendação de Jogos

Mateus Valério, 19/0035616

Maylla Krislainy, 19/0043873

Abril de 2026

I. Introdução

Este projeto propõe o desenvolvimento de um sistema de recomendação de jogos eletrônicos baseado na abordagem de *Content-Based*. O sistema considera um catálogo de 50 jogos, cada um descrito por três atributos categóricos: gênero, perspectiva de câmera e categoria de jogo.

A partir dessas características, os itens são representados em um espaço vetorial, permitindo a comparação entre jogos com base em similaridade. O sistema é capaz de receber o perfil de um novo usuário, construído a partir da avaliação de um subconjunto de jogos, e retornar recomendações personalizadas de acordo com suas preferências.

A aplicação inclui uma interface interativa para coleta dessas avaliações e um mecanismo de recomendação que identifica os k jogos mais similares ao perfil do usuário.

II. Descrição dos Dados

I. Catálogo de Jogos

Os dados utilizados neste projeto foram obtidos a partir de um dataset público de jogos da plataforma Steam, disponível no Kaggle [3]. O conjunto original continha milhares de jogos com diversas informações associadas.

Inicialmente, foi desenvolvido um algoritmo de filtragem para selecionar apenas jogos que possuíssem ao menos uma das três características definidas no escopo do projeto: gênero, perspectiva e categoria. Após essa etapa, o conjunto foi reduzido para aproximadamente 19 mil jogos.

Em seguida, foi aplicado um segundo processo de seleção para compor o catálogo final de 50 jogos. Desses, cerca de 40 correspondem aos títulos mais populares da plataforma (com base no número de usuários que possuem o jogo), enquanto os demais foram selecionados de forma aleatória. Essa estratégia foi adotada para garantir um equilíbrio entre jogos conhecidos e diversidade no conjunto de dados.

Cada jogo é descrito pelos três atributos listados na Tabela 1.

Tabela 1: *Atributos e valores possíveis de cada jogo.*

Atributo	Valores possíveis
Gênero	Shooter, RPG, Survival, Survival Horror, Souls-like, Simulation
Perspectiva	First-Person, Third-Person, 2D
Categoria	Singleplayer, Co-op, Multiplayer

Juntos, esses três atributos formam o perfil de cada jogo e são usados tanto na geração da matriz de avaliações quanto na definição dos tipos de usuários.

II. Matriz de Utilidade

A matriz de utilidade [2] tem dimensão 100×50 (usuários $\times$ jogos), com notas inteiras de 1 a 5. Células vazias indicam que o usuário não avaliou aquele jogo. Cada usuário avalia cerca de 65% dos jogos disponíveis (`RATING_RATE = 0.65`), deixando a matriz com aproximadamente 35% de células em branco.

II.1 Perfis de Usuário

Para que as avaliações reflitam comportamentos realistas, os 100 usuários foram gerados a partir de sete perfis arquetípicos. A Tabela 2 apresenta os perfis utilizados.

Tabela 2: *Perfis de usuário usados na geração da matriz.*

Perfil	n
Action RPG Fan	17
Survival Fan	16
Competitive Shooter	17
Multiplayer Generalist	15
Souls Enjoyer	13
Simulation Fan	12
Casual Gamer	10
Total	**100**

Cada perfil define os gêneros, perspectiva e categoria de jogo preferidos. O perfil *Casual Gamer* não tem preferências definidas, simulando um jogador sem padrão claro de consumo.

II.2 Cálculo de Afinidade e Geração de Notas

A nota de cada usuário para cada jogo é definida em duas etapas. Primeiro, calcula-se a afinidade com base em uma pontuação ponderada:

- **Gênero**: 2 pontos (fator mais importante);
- **Perspectiva**: 1 ponto;
- **Categoria**: 1 ponto.

Com pontuação máxima de 4, a afinidade é classificada como: score $\geq 3 \Rightarrow$ *high*; score $= 2 \Rightarrow$ *medium*; score $\leq 1 \Rightarrow$ *low*.

Em seguida, a nota é sorteada de uma distribuição gaussiana com parâmetros definidos pelo nível de afinidade (Tabela 3) e arredondada para o inteiro mais próximo dentro da escala $[1,5]$.

Tabela 3: *Parâmetros das distribuições por afinidade.*

Nível	μ	σ	Faixa
high	4,5	0,5	4–5
medium	3,5	0,7	3–4
low	2,2	1,0	1–2

O ruído gaussiano é proposital: simula a variação natural de gostos individuais, em que um usuário pode dar uma nota baixa para um jogo do seu gênero favorito, ou gostar de um título fora do seu perfil. A semente fixa `SEED = 42` garante que a matriz possa ser reproduzida a qualquer momento.

III. Modelo de Recomendação

I. Content-Based

A abordagem adotada neste trabalho é a filtragem baseada em conteúdo (*Content-Based Filtering*), na qual as recomendações são geradas com base na similaridade entre os atributos dos itens (neste caso, jogos).

Diferentemente da filtragem colaborativa, que depende do comportamento coletivo de múltiplos usuários, a abordagem baseada em conteúdo constrói um perfil individual a partir das preferências explícitas do usuário [5]. Assim, jogos com características semelhantes àqueles bem avaliados tendem a ser recomendados.

No contexto deste projeto, cada jogo é descrito por três atributos categóricos: gênero, perspectiva e categoria, que são utilizados para determinar a similaridade entre os itens.

II. Representação do Usuário

Os jogos são representados em um espaço vetorial por meio da técnica de *One-Hot Encoding* [1], resultando em vetores binários de dimensão 12, correspondentes a todas as possíveis características.

Nossa equipe optou pela escolha dessa técnica, em detrimento do uso de TF-IDF, devido à natureza dos dados utilizados. Enquanto o TF-IDF é mais adequado para representações textuais não estruturadas, nas quais a frequência e a raridade dos termos carregam informação relevante, no presente projeto as características dos jogos são categóricas, discretas e previamente definidas.

Nesse contexto, não há noção de frequência ou importância relativa entre os atributos, uma vez que todas as características possuem o mesmo peso semântico na descrição dos itens. Assim, o uso de *One-Hot Encoding* permite uma representação mais apropriada, preservando a distinção entre categorias sem introduzir vieses relacionados à frequência dos atributos.

O perfil do usuário é construído a partir das avaliações fornecidas durante a etapa de interação com a interface. Para isso, são considerados apenas os jogos avaliados acima de um determinado limiar (threshold), definido empiricamente.

A partir desses jogos, calcula-se um vetor de preferência do usuário por meio de uma média ponderada dos vetores dos itens avaliados, onde os pesos correspondem às notas atribuídas. Formalmente, o vetor de preferência $\mathbf{p}$ é dado por:

$$\mathbf{p} = \frac{\sum_{i \in I} w_i \cdot \mathbf{x}_i}{\sum_{i \in I} w_i} \tag{1}$$

onde $\mathbf{x}_i$ é o vetor do jogo i, w_i é o peso associado à avaliação do usuário, e I é o conjunto de jogos considerados.

III. Similaridade por Cosseno

Para medir a proximidade entre o vetor de preferência do usuário e os vetores dos jogos do catálogo, utiliza-se a similaridade do cosseno.

$$\text{sim}(\mathbf{p}, \mathbf{x}) = \frac{\mathbf{p} \cdot \mathbf{x}}{\|\mathbf{p}\| \cdot \|\mathbf{x}\|} \tag{2}$$

Essa métrica avalia o ângulo entre dois vetores no espaço vetorial, sendo amplamente utilizada em problemas de recomendação baseados em conteúdo [7]. Valores próximos de 1 indicam alta similaridade entre os perfis, enquanto valores próximos de 0 indicam baixa similaridade.

IV. Geração das Recomendações

Após a construção do vetor de preferência do usuário, calcula-se a similaridade entre esse vetor e todos os jogos disponíveis no catálogo.

Os jogos são então ordenados de acordo com o valor de similaridade, e os k itens mais próximos são selecionados como recomendações. Esse processo é equivalente à aplicação do algoritmo *K-Nearest Neighbors* (KNN) [6] no espaço vetorial de itens, onde o vetor do usuário atua como ponto de consulta.

Por fim, jogos já avaliados pelo usuário são removidos da lista final, garantindo que apenas novos itens sejam recomendados.

IV. Interface e Fluxo do Usuário

A interface foi desenvolvida como uma aplicação web com frontend em **Angular** [4] e backend em **Python**, e é dividida em trêsetapas sequenciais indicadas por um painel de progresso lateral.

I. Cadastro

O usuário informa um nome para personalizar a sessão e clica em *Começar* (Figura 1).

Figura 1: *Tela de cadastro do usuário.*

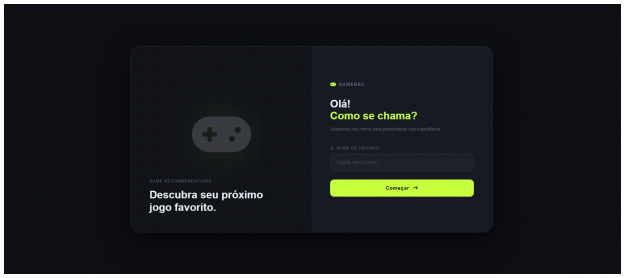

II. Seleção e Avaliação de Jogos

O sistema exibe os 10 jogos mais populares. O usuário seleciona entre 5 e 10 títulos que conhece e vai para a próxima etapa (Figura 2).

Figura 2: *Tela de seleção com 5 jogos marcados.*

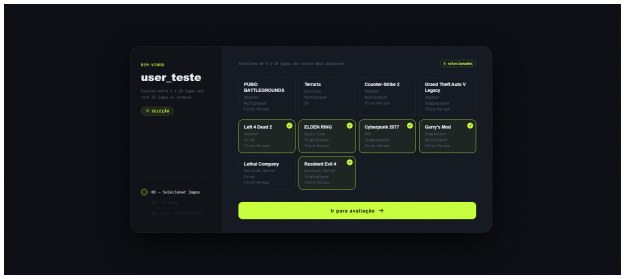

Em seguida ele deve atribui uma nota de 1 a 5 estrelas para cada um dos jogos selecionados (Figura 3). Essas notas formam o vetor de perfil enviado ao modelo.

Figura 3: *Tela de avaliação com notas por estrelas.*

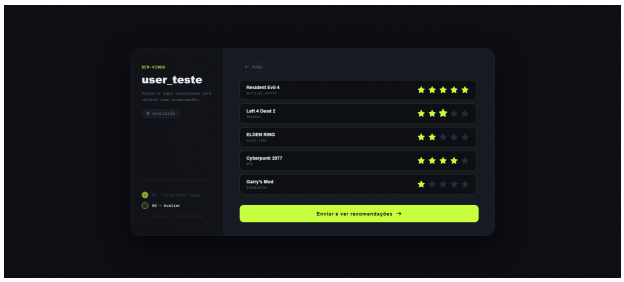

III. Recomendações

O backend processa o perfil e retorna os jogos recomendados em ordem de compatibilidade (Figura 4). Cada item exibe o nome, os atributos e um percentual de similaridade com o perfil do usuário.

Figura 4: *Tela de recomendações com scores de compatibilidade.*

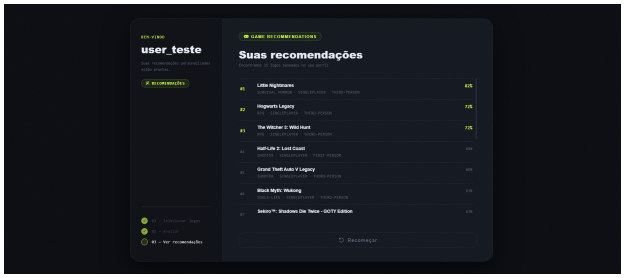

V. Resultados

I. Exemplo de Execução

Para ilustrar o funcionamento do sistema, apresenta-se a execução realizada com o usuário `user_teste`. Na etapa de seleção, foram escolhidos 5 jogos do top 10 mais populares (Figura 2), aos quais foram atribuídas notas de 1 a 5 estrelas na etapa de avaliação (Figura 3).

Tabela 4: *Jogos avaliados pelo* `user_teste`.

Jogo	Gênero	Nota
Resident Evil 4	Survival Horror	5
Cyberpunk 2077	RPG	4
Left 4 Dead 2	Shooter	3
ELDEN RING	Souls-like	2
Garry's Mod	Simulation	1

Com base nessas avaliações, o sistema construiu o vetor de preferência do usuário e calculou a similaridade com os demais jogos do catálogo. Os resultados são apresentados na Figura 4 e resumidos na Tabela 5.

Tabela 5: *Top recomendações geradas para o* `user_teste`.

Jogo	Gênero	Score
Little Nightmares	Survival Horror	82%
Hogwarts Legacy	RPG	72%
The Witcher 3: Wild Hunt	RPG	72%
Half-Life 2: Lost Coast	Shooter	68%
Grand Theft Auto V Legacy	Shooter	68%
Black Myth: Wukong	Souls-like	63%
Sekiro: Shadows Die Twice	Souls-like	63%

Os resultados mostram coerência com as preferências indicadas: os jogos mais bem recomendados pertencem aos gêneros com notas mais altas (Survival Horror e RPG), enquanto Souls-like aparece com score menor, refletindo a nota baixa atribuída ao ELDEN RING. A ausência de jogos de Simulation e o score reduzido de Shooter também são esperados, dado que Garry's Mod recebeu nota 1 e Left 4 Dead 2 recebeu nota 3.

II. Limitações

A especificação do projeto prevê a construção de uma matriz de utilidade, a qual foi devidamente elaborada conforme descrito na Seção de Dados. No entanto, devido à escolha da abordagem baseada em conteúdo (*Content-Based Filtering*), essa matriz não é utilizada diretamente no processo de recomendação.

Em métodos de filtragem colaborativa, a matriz de utilidade desempenha um papel central, sendo empregada para identificar similaridades entre usuários e inferir preferências a partir do comportamento coletivo. Entretanto, no presente trabalho, as recomendações são geradas exclusivamente a partir das características dos itens, tornando a utilização dessa matriz desnecessária para o funcionamento do modelo.

Foi realizada uma tentativa de incorporar a matriz de utilidade no processo de avaliação por meio de técnicas de validação cruzada (*cross-validation*), com o objetivo de determinar valores adequados para o parâmetro k e analisar métricas como precisão, recall, F1-score e NDCG.

Contudo, os experimentos indicaram que o aumento do valor de k resultava consistentemente em melhorias nas métricas avaliadas, especialmente em recall e NDCG. Esse comportamento é esperado, uma vez que valores maiores de k tendem a aumentar a cobertura das recomendações, favorecendo métricas baseadas em recuperação de itens relevantes.

Dessa forma, os resultados obtidos não permitiram identificar um ponto ótimo claro para a escolha de k, tornando a análise inconclusiva para os objetivos do projeto. Esse cenário está relacionado à natureza da abordagem baseada em conteúdo que não depende diretamente da matriz de utilidade. Além disso, reconhece-se que a implementação e análise dessas métricas exigem maior aprofundamento técnico, o que limita a precisão dos resultados obtidos nesta etapa do projeto.

VI. Conclusão

Este projeto teve como objetivo o desenvolvimento de um sistema de recomendação de jogos eletrônicos baseado na abordagem de *Content-Based Filtering*, considerando um catálogo estruturado de 50 jogos descritos por atributos categóricos.

Como resultado, foi possível construir um conjunto de dados coerente, incluindo a seleção dos jogos, a definição de suas características e a geração de uma matriz de utilidade com perfis simulados. Além disso, foi implementado um modelo de recomendação funcional, baseado na representação vetorial dos itens e na utilização de similaridade do cosseno em conjunto com o algoritmo KNN. O sistema também conta com uma interface interativa que permite ao usuário fornecer suas preferências e receber recomendações personalizadas.

Apesar dos resultados satisfatórios, observou-se que a matriz de utilidade teve um papel limitado dentro da abordagem adotada, uma vez que o modelo baseado em conteúdo não depende diretamente de interações entre múltiplos usuários.

Como possível extensão, destaca-se a adoção de uma abordagem híbrida, combinando filtragem baseada em conteúdo com filtragem colaborativa. Nesse cenário, a matriz de utilidade poderia ser explorada de forma mais efetiva, por exemplo, por meio da predição de avaliações de rating utilizando modelos regressivos baseados em perfis de usuários semelhantes, mantendo o uso de medidas de similaridade como o cosseno e estratégias baseadas em vizinhança.

Referências

[1] 365 Data Science. How to build a recommendation system in python. `https://365datascience.com/tutorials/how-to-build-recommendation-system-in-python/`, 2023. Acesso em: abr. 2026. 2

[2] Gediminas Adomavicius and Alexander Tuzhilin. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, 2005. `https://pages.stern.nyu.edu/~atuzhili/pdf/TKDE-Paper-as-Printed.pdf`. 1

[3] Fronko Games. Steam games dataset. https://www.kaggle.com/datasets/fronkongames/steam-games-dataset, 2023. Acesso em: abr. 2026. 1

[4] Google LLC. Angular: Platform for building web applications. https://angular.io, 2016. 3

[5] IteratorsHQ. An introduction to recommender systems: 9 easy examples. https://www.iteratorshq.com/blog/an-introduction-recommender-systems-9-easy-examples/, 2023. Acesso em: abr. 2026. 2

[6] Fabian Pedregosa et al. Scikit-learn: Machine learning in Python. https://scikit-learn.org, 2011. 3

[7] Francesco Ricci, Lior Rokach, and Bracha Shapira. *Recommender Systems Handbook*. Springer, New York, 2 edition, 2015. 2